

Proyecto 1 - Detección de actividad física

Jhonny Camilo Beltran Hernandez - Diego Alejandro Vera Ortega
Pontificia Universidad Javeriana
Aprendizaje de Máquina Embebido - TinyML

29 de julio de 2026

1. Introducción

El reconocimiento de actividad física humana (*Human Activity Recognition*, HAR) es una aplicación fundamental del aprendizaje automático embebido (*TinyML*), con utilidad en áreas como salud, deportes y vigilancia de seguridad.

En este proyecto se diseñó, entrenó y validó un clasificador de cinco actividades físicas, bajar escaleras, caminar, correr, quieto y subir escaleras, utilizando datos del acelerómetro de dos celulares inteligentes, a través de la plataforma Edge Impulse, se realizó la adquisición de datos de los experimentos realizados para entrenar el modelo, al igual que la partición de los datos para el entrenamiento y despliegue del modelo.

2. Recolección de datos

Los datos se capturaron utilizando el acelerómetro triaxial integrado en un teléfono inteligente (iPhone), registrando aceleraciones en los tres ejes espaciales (accX, accY, accZ) para caracterizar el movimiento corporal [1].

La adquisición y etiquetado de las señales se realizó mediante la plataforma Edge Impulse, la cual permite recolectar y gestionar datos provenientes de sensores para el desarrollo de modelos de aprendizaje automático [2].

Durante la experimentación, el dispositivo se colocó en la región de la cadera del participante, una ubicación comúnmente utilizada para capturar patrones de locomoción humana como caminar, correr o subir escaleras [3].

Las señales obtenidas corresponden a aceleraciones triaxiales en el tiempo, utilizadas posteriormente para el reconocimiento automático de actividades mediante técnicas de aprendizaje automático [4].

En total se recolectaron 31 minutos y 12 segundos de señal, divididos en 23 muestras de entrenamiento y 5 muestras de prueba (partición 79 %/21 %). Cada muestra tiene una duración aproximada de 1 minuto 36 segundos, garantizando variabilidad temporal suficiente por clase. Se incluye además una imagen del proceso de experimentación para la obtención de los datos, correspondiente a la actividad *correr* (Fig. 1).



Figura 1: Actividad para recolección de datos

3. Entrenamiento del Modelo


3.1. Preprocesamiento (*Impulse*)

El *impulse* de Edge Impulse define la cadena completa de procesamiento. La señal temporal se segmenta con una **ventana de 2,069 ms** y un **stride de 1,000 ms**. Sobre cada ventana se aplica **análisis espectral** (*Spectral Features*) en los tres ejes, generando un vector de **39 características** que alimenta el clasificador, usando las siguientes características.

Clase	Descripción
bajarescaleras	Descender escaleras
caminar	Marcha normal
correr	Correr continuamente
quieto	Sin movimiento voluntario
subirescaleras	Ascender escaleras

3.2. Arquitectura y Parámetros de Entrenamiento

Se utilizó una red neuronal densa (*fully connected*) con la siguiente arquitectura:



Los hiperparámetros de entrenamiento fueron:

Parámetro	Valor
Ciclos de entrenamiento	45
Tasa de aprendizaje	0.0005
Optimizador	Estándar (sin <i>learned optimizer</i>)
Procesador	CPU
Versión del modelo	Cuantizado (int8)

3.3. Resultados del Entrenamiento

El modelo alcanzó una exactitud de 91.8 % y una pérdida de 0.21, en el modelo cuantizado (int8) y en la versión del modelo sin cuantizar (float32) se obtuvo una exactitud de 92.1 % y una pérdida de 0.21 sobre el conjunto de validación (Figura 2). La matriz de confusión evidencia que *caminar* es la clase mejor discriminada (97.7 %), seguida de *correr* (95.6 %), mientras que *subirescaleras* presenta la mayor confusión (76 %), principalmente con *caminar* y *correr*.




Figura 2: Resultados de entrenamiento incluyendo matriz de confusión.

4. Pruebas de Rendimiento

4.1. Métricas Globales

Las métricas de validación del modelo cuantizado (int8) se resumen a continuación (Figura 3):

Métrica	Valor
Área bajo la curva ROC (AUC)	0.99
Precisión promedio ponderada	0.92
Recall promedio ponderado	0.91
F1-score promedio ponderado	0.91

El AUC de 0.99 indica una capacidad de discriminación alta entre clases. El *data explorer* muestra agrupaciones espaciales definidas, con mayor solapamiento en las clases de movimiento escalera.



Figura 3: Métricas de validación y explorador de datos clasificados. Tiempo de inferencia: 1 ms; RAM: 1.4 KB; Flash: 15.1 KB.

Enlace al Proyecto en Edge Impulse

El proyecto desarrollado en la plataforma Edge Impulse se encuentra disponible públicamente en el siguiente enlace:

<https://studio.edgeimpulse.com/public/968532/live>

4.2. Validación en Tiempo Real

Se realizaron pruebas en vivo capturando señal con el smartphone. La Figura 4 muestra que durante la actividad **quieto** el modelo asigna probabilidades de 0.91–1.00 a la clase correcta, y durante **correr** alcanza probabilidades de 0.91–1.00 de forma consistente a lo largo de 50+ ventanas consecutivas.




Figura 4: Inferencia en tiempo real sobre el smartphone. Columnas: bajar escaleras, caminar, correr, quieto, subir escaleras.



Figura 5: Inferencia en tiempo real a las actividades.

5. Conclusiones

- Se diseñó un sistema HAR de cinco clases basado en acelerómetro de smartphone, logrando una exactitud de **91.8 %** (int8) con un modelo cuantizado de solo 15.1 KB de Flash.
- La clase subirescaleras presentó la menor exactitud (76 %), posiblemente debido a su similitud cinemática con caminar. Aumentar el número de muestras o agregar características adicionales (por ejemplo, giroscopio y barómetro) podría mejorar su discriminación.
- El tiempo de inferencia de 1 ms confirma la viabilidad de ejecución en tiempo real sobre hardware embebido de bajo consumo, cumpliendo el paradigma TinyML.
- La plataforma Edge Impulse facilitó el flujo completo de trabajo (captura, preprocesamiento, entrenamiento y despliegue), reduciendo significativamente el tiempo de desarrollo de soluciones de inteligencia artificial.

Referencias

- [1] E. Cavita-Huerta et al. "Clasificación de actividad física mediante señales de acelerometría". En: *Pädi* 12.Especial (2024), págs. 50-56.
- [2] Edge Impulse Inc. *Edge Impulse Documentation*. Accessed: 2026. 2026. URL: <https://docs.edgeimpulse.com>.
- [3] W. Fadel, J. Urbanek, V. Zipunnikov et al. "Prediction of walking modalities using raw accelerometry data". En: *Statistics in Biosciences* (2020). Author manuscript available in PubMed Central.
- [4] Vijay Janapa Reddi et al. *Machine Learning Systems: Principles and Practices of Engineering Artificially Intelligent Systems*. Open Book, 2023. URL: <https://mlsysbook.ai>.